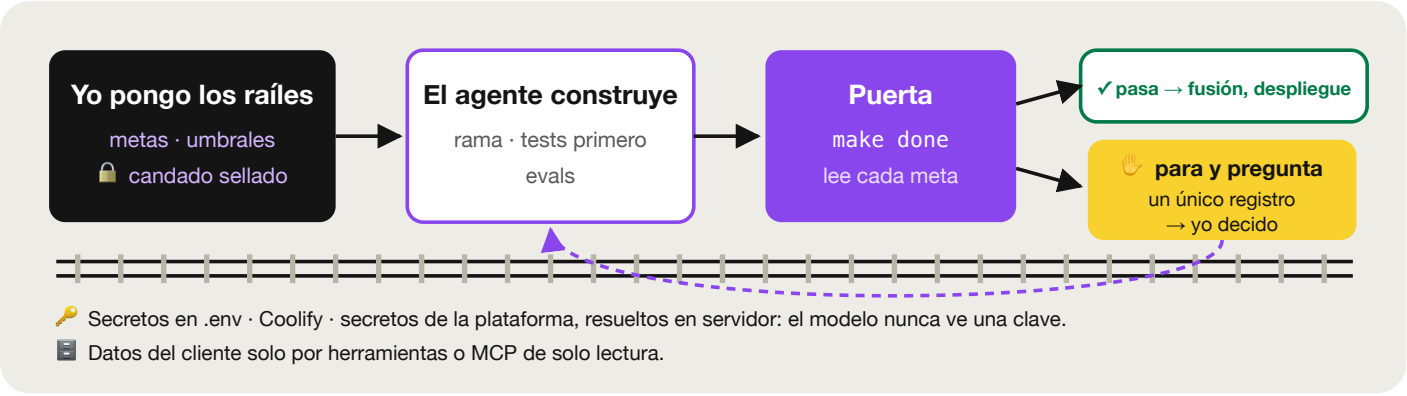
Cómo trabajo con IA

Samuel Viciana · AI Forward Deployed Engineer · prueba técnica de indigo.ai, parte 1

No guío al agente. **Lo encarrilo.** Claude Code escribe la mayor parte del código; yo decido qué significa «terminado» antes de que escriba una línea, y nada de lo que construye puede mover esa línea.



1 · Mi forma de trabajar

- **Primero los raíles.** Cada meta tiene un umbral, el comando que la mide y el archivo que escribe. Un candado sha256 las sella y solo yo lo regenero: el agente lee las metas, no puede editarlas.
- **Un único registro de decisiones.** Si una meta falla tras dos intentos medidos, o hace falta dinero, una dependencia, una acción hacia fuera o un criterio, el agente para, lo anota y me pregunta, con opciones y una recomendación.
- **Test ≠ eval.** Código de backend: tests primero y umbral de cobertura. Lo que consume un modelo (descripciones de herramientas, errores, el prompt) se mide con un modelo: 81 casos de herramientas revisados a mano, 150 casos frase→herramienta con un modelo local y simulaciones en la plataforma leídas contra los datos.
- **Diseñar para un modelo es distinto.** Un backend se juzga por sus tests; una interfaz que consume un LLM, por lo que el modelo hace con ella. Por eso cada respuesta dice lo que no pudo encajar (términos que faltan, fuera de presupuesto, agotado con alternativas) y cada error dice cómo corregir la llamada.
- **Los secretos nunca llegan a un modelo.** El agente no lee claves; los datos del cliente llegan al modelo solo por herramientas o MCP de solo lectura.

2 · Cuando salió mal

- La plataforma importaba el *summary* de cada operación, no su *description*: el modelo recibía una línea y perdía toda la guía, sin ningún aviso. Solo lo vi ejecutando el agente en la plataforma. Ahora pruebo en el consumidor real, no solo en mi banco.
- Un juez LLM suspendía productos reales como «inventados» tres tandas seguidas: no veía el catálogo. Parchear criterios fallo a fallo no convergía; ahora el juez evalúa comportamiento y contradicciones, y yo leo cada Fail contra los datos.
- El MCP decía «Connected» y cada llamada era un 401. Un log de una línea por petición mostró que la plataforma enviaba el nombre del secreto (19 caracteres) en vez de la clave (64). Cuando un cliente movido por un modelo falla en silencio: instrumentar, no adivinar.

3 · En la reunión

Mantengo una decisión cuando la evidencia sale de los datos del propio cliente. Elegí el modelo con una prueba controlada de cinco; dos que lideraban un benchmark público respondían en otro idioma o filtraban tokens de herramientas. Enseño la conversación, no el benchmark. Cambio de opinión cuando el cliente trae una restricción que no tenía (coste, cumplimiento, un sistema de referencia) o mejor evidencia: repito la misma prueba y dejo escrita la decisión y su porqué. Un umbral nunca se mueve para que un resultado pase.

La ingeniería es valor añadido. El valor de SpaceX no es el metal ni el combustible; es lo difícil que es convertirlos en un cohete que vuelve. Los modelos son mi materia prima. Mi trabajo es la parte difícil a su alrededor: usar herramientas como **Claude Code** de forma profesional, segura y continua. No guiadas: encarriladas.