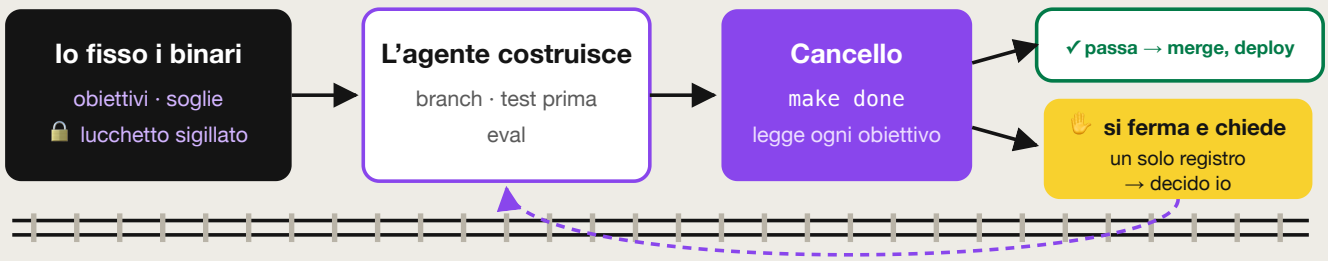
Come lavoro con l'IA

Samuel Viciana · AI Forward Deployed Engineer · prova tecnica indigo.ai, parte 1

Non guido l'agente. **Lo metto sui binari.** Claude Code scrive la maggior parte del codice; io decido cosa significa «fatto» prima che scriva una riga, e niente di ciò che costruisce può spostare quella linea.



🔑 Segreti in .env · Coolify · segreti della piattaforma, risolti lato server: il modello non vede mai una chiave.
🗄️ Dati del cliente solo tramite tool o MCP in sola lettura.

1 · Il mio modo di lavorare

- **Prima i binari.** Ogni obiettivo ha una soglia, il comando che la misura e il file che scrive. Un lucchetto sha256 li sigilla e solo io lo rigenero: l'agente legge gli obiettivi, non può modificarli.
- **Un solo registro delle decisioni.** Se un obiettivo fallisce dopo due tentativi misurati, o servono soldi, una dipendenza, un'azione verso l'esterno o un giudizio, l'agente si ferma, lo annota e mi chiede, con opzioni e una raccomandazione.
- **Test ≠ eval.** Codice backend: prima i test e una soglia di copertura. Ciò che un modello consuma (descrizioni dei tool, corpi d'errore, il prompt) si misura con un modello: 81 casi di tool rivisti a mano, 150 casi frase→tool su un modello locale e simulazioni sulla piattaforma lette contro i dati.
- **Progettare per un modello è diverso.** Un backend si giudica dai suoi test; un'interfaccia usata da un LLM, da ciò che il modello ne fa. Per questo ogni risposta dice cosa non ha potuto abbinare (termini mancanti, fuori budget, esaurito con alternative) e ogni errore dice come correggere la chiamata.
- **I segreti non arrivano mai a un modello.** L'agente non legge chiavi; i dati del cliente arrivano al modello solo tramite tool o MCP in sola lettura.

2 · Quando è andata male

- La piattaforma importava il *summary* di ogni operazione, non la *description*: il modello riceveva una riga e perdeva tutta la guida, in silenzio. L'ho visto solo eseguendo l'agente sulla piattaforma. Ora provo sul consumatore reale, non solo sul mio banco di prova.
- Un giudice LLM bocciava prodotti reali come «inventati» per tre giri di fila: non vedeva il catalogo. Correggere i criteri un errore alla volta non convergeva; ora il giudice valuta comportamento e contraddizioni, e io leggo ogni Fail contro i dati.
- L'MCP diceva «Connected» e ogni chiamata era un 401. Un log di una riga per richiesta ha mostrato che la piattaforma inviava il nome del segreto (19 caratteri) invece della chiave (64). Quando un client guidato da un modello fallisce in silenzio: strumentare, non indovinare.

3 · Nella stanza

Mantengo una scelta quando l'evidenza viene dai dati del cliente. Ho scelto il modello con un test controllato su cinque; due che guidavano un benchmark pubblico rispondevano nella lingua sbagliata o lasciavano trapelare token dei tool. Mostro la conversazione, non il benchmark. Cambio idea quando il cliente porta un vincolo che non avevo (costi, compliance, un sistema di riferimento) o un'evidenza migliore: ripeto lo stesso test e registro la decisione e il suo perché. Una soglia non si sposta mai per far passare un risultato.

L'ingegneria è valore aggiunto. Il valore di SpaceX non è il metallo né il carburante; è quanto è difficile trasformarli in un razzo che torna indietro. I modelli sono la mia materia prima. Il mio lavoro è la parte difficile intorno a loro: usare strumenti come **Claude Code** in modo professionale, sicuro e continuo. Non guidati: sui binari.